État de l'art : Résumé de graphes RDF

1 Contexte général

Les graphes de connaissances RDF (*RDF Knowledge Graphs*) constituent un moyen standard de représenter des connaissances structurées sous la forme de triplets *(sujet, prédicat, objet)*. Toutefois, leur taille et leur complexité rendent leur compréhension et leur exploitation difficiles, en particulier pour la formulation de requêtes SPARQL. Afin de répondre à cette problématique, plusieurs travaux ont été proposés pour produire des **résumés de graphes RDF**, c'est-à-dire des sous-graphes plus compacts conservant les éléments jugés essentiels.

Dans cette section, nous présentons et analysons trois approches représentatives de l'évolution de ce domaine :

1) une approche **orientée requêtes** et fondée sur des **propriétés logiques** ;
2) une approche **structurelle** basée sur des **centralités** et l'**apprentissage automatique** ;
3) une approche basée sur des **représentations vectorielles** (*embeddings*).

2 Query-Oriented Summarization of RDF Graphs (Čebirić et al., 2015)

2.1 Objectif

L'objectif principal de cette approche est de définir ce qu'est un **bon résumé RDF du point de vue des requêtes SPARQL**. Les auteurs ne cherchent pas à identifier les éléments les plus importants du graphe, mais à garantir que le résumé préserve correctement les capacités de réponse aux requêtes.

2.2 Principe fondamental

L'approche repose sur une définition **formelle et logique** du résumé. Deux propriétés fondamentales sont introduites :

— **Représentativité** : toute requête SPARQL ayant une réponse sur le graphe original doit également avoir une réponse sur le résumé. Si une requête a un résultat sur le graphe saturé (G), elle doit en avoir un sur le résumé saturé (SG)

— **Précision** : Toute requête pouvant être mise en correspondance avec le résumé doit pouvoir l'être sur au moins un graphe original correspondant à ce résumé. La qualité est effectivement évaluée selon ces critères logiques (Définitions 1 et 2) plutôt que sur des statistiques d'usage

Ainsi, la qualité du résumé est évaluée selon des **critères logiques**, indépendamment de la fréquence ou de l'usage réel des requêtes.

2.3 Méthode

Les auteurs proposent deux types de résumés :

— **Baseline summary** :

    - basé sur la structure des propriétés (règles DNT1-DNT4). Sa complexité de calcul est de O(G 2) ;
    - regroupe les ressources partageant des motifs structurels similaires ;
    - très compact et calculable efficacement.
- **Refined summary** :
    - plus précis ;
    - distingue plus finement les types et relations ;
    - mais avec un coût computationnel beaucoup plus élevé avec une complexité de O(G5).

Ces résumés prennent en compte à la fois les données explicites et implicites (via le raisonnement RDFS).

2.4 Évaluation

L'évaluation est exclusivement **théorique**. Les auteurs démontrent formellement que leurs résumés satisfont les propriétés de représentativité et de précision. Aucune comparaison quantitative ou empirique avec d'autres approches n'est réalisée.

2.5 Caractérisation de l'approche

Cette approche se distingue par :

- une forte **orientation requêtes** ;
- une vision **logique et formelle** du résumé ;
- l'absence de notion d'importance ou de hiérarchisation ;
- l'absence de machine learning.

3 SumMER : Structural Summarization for RDF/S Knowledge Graphs (Troullinou et al., 2023)

3.1 Objectif

L'approche SumMER vise à produire un **résumé structurel lisible** du graphe RDF, mettant en évidence les **concepts les plus importants** du schéma. Contrairement à l'approche précédente, l'objectif est ici de **sélectionner un nombre limité d'éléments (top-k)** représentatifs du graphe.

3.2 Principe fondamental

L'idée centrale est que l'importance d'une classe du schéma RDF peut être estimée à partir :

- de sa **position structurelle** dans le graphe ;
- et de son **usage réel par les utilisateurs**.

Pour cela, SumMER combine plusieurs mesures de centralité structurelle et utilise un modèle de machine learning pour apprendre automatiquement leur importance relative.

3.3 Méthode

L'approche se déroule selon les étapes suivantes :

1. Extraction du **schéma RDF** (classes et propriétés).
2. Calcul de **huit mesures de centralité** pour chaque classe.
3. Ajout du **nombre d'instances** comme caractéristique supplémentaire.

4. Apprentissage d'un **modèle de régression supervisée** à partir de logs de requêtes SPARQL.
5. Sélection des **top-k classes les plus importantes**.
6. Connexion des classes sélectionnées via une **approximation du problème du Steiner Tree** afin d'obtenir un résumé connexe.

Le résumé final est un sous-graphe structurel centré sur les classes jugées les plus importantes.

3.4 Évaluation

L'évaluation est **empirique et quantitative**, basée sur :

— des graphes RDF réels (par exemple DBpedia, SWDF) ;

— des logs de requêtes SPARQL réelles.

La qualité du résumé est mesurée à l'aide de la **coverage**, qui évalue la capacité du résumé à couvrir les classes et propriétés utilisées dans les requêtes. Les résultats montrent que SumMER améliore significativement la couverture par rapport aux approches existantes.

3.5 Caractérisation de l'approche

SumMER se caractérise par :

— une approche **structurelle** ;

— une notion explicite d'**importance** ;

— une sélection **node-centric** ;

— l'utilisation du **machine learning** ;

— la production de résumés **top-k**.

4 Constructing Semantic Summaries Using Embeddings (Pappas et al., 2024)

4.1 Objectif

Cette approche vise à améliorer à la fois la **scalabilité** et la **qualité sémantique** des résumés RDF. Contrairement aux méthodes fondées sur des mesures de centralité explicites (telles que PageRank ou Betweenness), dont le calcul devient coûteux sur des graphes de grande taille, cette méthode propose d'exploiter des **représentations vectorielles apprises automatiquement**.

L'objectif est de produire un **résumé structurel non-quotient**, c'est-à-dire un sous-graphe composé uniquement d'éléments existants du graphe original, sans fusion d'entités, tout en garantissant :

— une bonne couverture des éléments réellement utilisés ;

— une cohérence structurelle ;

— une applicabilité aux graphes RDF massifs ;

— une adéquation avec l'usage réel observé à travers les requêtes utilisateurs.

4.2 Principe fondamental

Le principe central de l'approche repose sur l'hypothèse suivante :

> Les embeddings de graphes capturent implicitement la structure et la sémantique d'un graphe RDF.

Les représentations vectorielles apprises à partir du graphe encodent :

— les relations structurelles ;
— les similarités contextuelles ;
— les co-occurrences entre entités et propriétés.

Ainsi, l'importance d'un nœud ou d'une propriété peut être **apprise directement à partir de son embedding**, sans calcul explicite de mesures de centralité.

4.3 Résumé RDF basé sur les embeddings

Sur la base de ce principe, la construction du résumé s'effectue en quatre étapes principales :

1. Génération d'embeddings RDF2Vec pour les nœuds et les propriétés ;
2. Apprentissage supervisé de l'importance des nœuds et des arêtes ;
3. Sélection des top-k nœuds les plus importants ;
4. Connexion des nœuds sélectionnés via une approximation du Steiner Tree pondéré (SDIST).

4.3.1 Génération des embeddings RDF2Vec

Random Walks À partir du graphe RDF $G = (V, E)$, des marches aléatoires sont générées afin de produire des séquences de la forme :

$$v_1, p_1, v_2, p_2, v_3, \ldots$$

où $v_i \in V$ représentent des nœuds et $p_i \in E$ des propriétés RDF.
Ces séquences sont analogues à des phrases en traitement automatique des langues.

Apprentissage des représentations vectorielles Les séquences générées sont utilisées pour entraîner un modèle Word2Vec (architecture Skip-gram). Chaque élément e (nœud ou propriété) est représenté par un vecteur :

$$embedding(e) \in \mathbb{R}^d$$

Ces vecteurs capturent les similarités structurelles, les proximités sémantiques et les patterns relationnels du graphe.

4.3.2 Apprentissage supervisé de l'importance

Construction du signal supervisé Les logs de requêtes SPARQL sont utilisés afin de définir un signal d'importance.

Pour chaque nœud v, on définit :

$$I_{node}(v) = \frac{\text{nombre de requêtes contenant } v}{\text{nombre total de requêtes}}$$

De manière analogue, pour chaque arête e :

$$I_{edge}(e) = \frac{\text{nombre de requêtes contenant } e}{\text{nombre total de requêtes}}$$

Ces valeurs constituent les labels d'apprentissage.

Apprentissage des modèles de régression Deux modèles distincts sont entraînés :

Pour les nœuds :

$$f_{node} : embedding(v) \rightarrow I_{node}(v)$$

Un Decision Tree Regressor est utilisé afin de capturer des relations non linéaires entre les embeddings et l'importance.

Pour les arêtes :

$$f_{edge} : embedding(e) \rightarrow I_{edge}(e)$$

Un Support Vector Regressor (SVR) est employé afin d'estimer les poids des relations.

4.3.3 Sélection des top-k nœuds

Les scores d'importance prédits pour tous les nœuds sont triés par ordre décroissant. Les k nœuds les plus importants sont sélectionnés :

$$T = \{v_1, v_2, \ldots, v_k\}$$

Ces nœuds constituent les terminaux du résumé.

4.3.4 Construction du résumé via SDIST

Pondération des arêtes Chaque arête e reçoit un poids :

$$w(e) = f_{edge}(embedding(e))$$

Afin d'appliquer un algorithme de plus court chemin, un coût est défini comme :

$$c(e) = 1 - w(e)$$

Approximation du Steiner Tree L'algorithme SDIST est appliqué selon les étapes suivantes :

1. Calcul des plus courts chemins pondérés entre chaque paire de nœuds terminaux ;
2. Construction d'un graphe réduit complet sur ces terminaux ;
3. Calcul d'un arbre couvrant minimal (MST) sur ce graphe réduit ;
4. Remplacement des arêtes abstraites par leurs chemins correspondants dans le graphe original.

Résumé final Le résumé final est un sous-graphe du graphe RDF original qui :

— contient les nœuds les plus importants ;
— relie ces nœuds via des relations sémantiquement pertinentes ;
— préserve une structure cohérente ;
— reste non-quotient (aucune fusion d'entités).

4.4 Évaluation

L'évaluation de l'approche est à la fois **quantitative** et **comparative**. Elle vise à mesurer la qualité du résumé produit ainsi que sa capacité à passer à l'échelle sur des graphes RDF de grande taille. Les performances sont comparées à celles de l'approche SumMER, considérée comme une référence dans la littérature.

L'évaluation repose sur trois axes principaux : la qualité du résumé, la précision de la sélection des nœuds et l'efficacité computationnelle.

4.4.1 Métrique de Coverage

La métrique de **coverage** mesure la proportion d'éléments importants du graphe original capturés par le résumé. Elle permet d'évaluer dans quelle mesure le résumé préserve l'information pertinente.

Formellement, la coverage peut être exprimée comme :

$$Coverage = \frac{\sum_{e \in R} importance(e)}{\sum_{e \in G} importance(e)}$$

où :

— R est l'ensemble des éléments (nœuds et arêtes) présents dans le résumé ;

— G est l'ensemble des éléments du graphe original ;

— $importance(e)$ est le score d'importance estimé.

Une coverage élevée indique que le résumé conserve une grande partie des éléments jugés importants selon le signal supervisé.

4.4.2 Nombre de vrais positifs

La qualité de la sélection des nœuds est également évaluée à travers le nombre de **vrais positifs**. Cette mesure consiste à comparer les nœuds sélectionnés par l'algorithme aux nœuds réellement importants identifiés dans les logs de requêtes.

Un nœud est considéré comme un vrai positif s'il :

— appartient au top-k sélectionné par le modèle ;

— figure également parmi les nœuds les plus fréquents dans les requêtes utilisateurs.

Cette métrique permet d'évaluer la précision du modèle de régression dans l'identification des entités pertinentes.

4.4.3 Temps d'exécution

L'efficacité computationnelle est mesurée par le temps d'exécution total de l'algorithme, incluant :

— la génération des embeddings ;

— l'apprentissage des modèles de régression ;

— la sélection des top-k nœuds ;

— la construction du résumé via SDIST.

Cette mesure est particulièrement importante pour les graphes RDF de grande taille, où les approches basées sur des mesures de centralité explicites deviennent coûteuses.

4.5 Caractérisation de l'approche

Cette approche se distingue par :

— une estimation de l'importance fondée sur des embeddings ;

— une prise en compte conjointe des nœuds et des arêtes ;

— une forte scalabilité sur des graphes RDF massifs ;

— une meilleure cohérence sémantique des chemins retenus ;

— une interprétabilité plus limitée que les méthodes fondées sur des centralités explicites.

5 Analyse comparative des approches de résumé RDF

Cette section présente une analyse comparative détaillée des trois approches étudiées : (i) l'approche orientée requêtes, (ii) l'approche SumMER basée sur les centralités, et (iii) l'approche récente fondée sur les embeddings.

L'analyse porte sur leurs objectifs, leurs principes méthodologiques, la nature des résumés produits, leur scalabilité ainsi que leurs performances expérimentales.

5.1 Objectifs et hypothèses

Les trois approches poursuivent des objectifs différents.

L'approche **Query-Oriented** vise principalement à préserver le comportement des requêtes SPARQL. Son objectif n'est pas d'identifier les entités les plus importantes, mais de garantir que les requêtes exécutées sur le graphe original produisent des résultats équivalents sur le résumé.

L'approche **SumMER** introduit une notion explicite d'importance structurelle. Elle cherche à produire un résumé non-quotient en sélectionnant les nœuds les plus centraux du graphe selon plusieurs mesures de centralité combinées par apprentissage automatique.

L'approche **Embeddings** adopte une perspective différente : elle suppose que l'importance d'un nœud ou d'une relation peut être apprise à partir de représentations vectorielles capturant implicitement la structure et la sémantique du graphe. Elle vise ainsi à améliorer à la fois la qualité du résumé et sa scalabilité.

5.2 Unité fondamentale du résumé

Les différences entre les approches apparaissent dès l'unité fondamentale considérée.

- Query-Oriented repose sur des motifs de requêtes (Basic Graph Patterns).
- SumMER sélectionne des nœuds individuels sur la base de leur centralité.
- L'approche Embeddings sélectionne également des nœuds individuels, mais leur importance est apprise à partir d'embeddings.

Ainsi, Query-Oriented est orientée usage, tandis que SumMER et Embeddings sont orientées importance.

5.3 Estimation de l'importance

Les méthodes diffèrent fortement dans la manière dont elles estiment l'importance des éléments du graphe.

Query-Oriented. Aucune mesure d'importance explicite n'est calculée. La pertinence d'un élément dépend uniquement de sa présence dans les requêtes observées.

SumMER. L'importance est dérivée de mesures de centralité explicites (PageRank, Degree, Betweenness, HITS), combinées via un modèle supervisé. Cette approche est interprétable mais coûteuse en calcul sur des graphes massifs.

Embeddings. L'importance est apprise par régression à partir des embeddings RDF2Vec, en utilisant les logs de requêtes comme signal supervisé. Cette méthode permet de capturer des signaux structurels et sémantiques plus complexes, sans calcul direct de centralités.

5.4 Construction du résumé

Les trois approches produisent un résumé structurel non-quotient, mais diffèrent dans la manière de connecter les éléments sélectionnés.

— Query-Oriented conserve les structures nécessaires aux requêtes.
— SumMER relie les top-k nœuds via une approximation du Steiner Tree.
— Embeddings utilise également un Steiner Tree, mais pondéré selon l'importance apprise des arêtes (SDIST).

L'approche Embeddings est la seule à intégrer explicitement un poids appris pour les relations, améliorant la cohérence sémantique des chemins retenus.

5.5 Qualité du résumé

La qualité est évaluée principalement via la métrique de coverage et le nombre de vrais positifs.

Les résultats expérimentaux montrent que :

— Query-Oriented garantit la fidélité aux requêtes mais ne maximise pas nécessairement la couverture globale.
— SumMER améliore la compacité structurelle, mais peut perdre certaines relations sémantiquement pertinentes.
— Embeddings obtient une meilleure coverage et un plus grand nombre de vrais positifs, indiquant une meilleure sélection des éléments importants.

5.6 Scalabilité

La scalabilité constitue un critère déterminant.

— Query-Oriented présente une complexité élevée liée aux opérations de raffinement et de saturation.
— SumMER souffre du coût des mesures de centralité sur de grands graphes.
— Embeddings réduit ces coûts en remplaçant les centralités explicites par des représentations vectorielles apprises, ce qui améliore significativement le passage à l'échelle.

5.7 Synthèse comparative

On peut résumer les différences principales comme suit :

Critère	**Query-Oriented**	**SumMER**	**Embeddings**
Orientation	Usage	Structure	Sémantique + Usage
Importance explicite	Non	Oui (centralités)	Oui (apprise)
Pondération des arêtes	Non	Non	Oui
Scalabilité	Faible	Moyenne	Élevée
Coverage	Moyenne	Bonne	Meilleure
Interprétabilité	Élevée	Élevée	Plus limitée

6 Conclusion de l'état de l'art

Ces travaux illustrent une évolution progressive des approches de résumé RDF, allant de définitions formelles orientées requêtes vers des méthodes empiriques fondées sur l'apprentissage automatique. Toutefois, l'ensemble de ces approches demeure principalement centré sur des éléments isolés (nœuds ou arêtes), alors que les requêtes SPARQL expriment des motifs structuraux impliquant plusieurs éléments simultanément. Cette observation constitue le point de départ de l'approche proposée dans la suite de ce travail.

7 Approche proposée : Résumé RDF basé sur des sous-graphes orientés requêtes

7.1 Motivation

L'analyse de l'état de l'art met en évidence que les approches existantes sélectionnent principalement des éléments isolés du graphe (nœuds ou arêtes) en évaluant leur importance individuelle. Cependant, les requêtes SPARQL ne portent pas sur des entités isolées, mais sur des motifs structuraux appelés *Basic Graph Patterns (BGP)*, impliquant simultanément plusieurs classes et relations.

Notre approche repose sur l'hypothèse suivante :

> L'unité naturelle d'usage d'un graphe RDF n'est pas le nœud isolé, mais le sous-graphe correspondant aux motifs de requêtes.

Nous proposons donc une méthode de résumé RDF centrée sur des **sous-graphes orientés requêtes**, plutôt que sur des nœuds individuels.

7.2 Définitions préliminaires

Soit un graphe RDF $G = (V, E)$, où :

— V est l'ensemble des nœuds (classes ou entités),

— E est l'ensemble des arêtes (propriétés RDF).

Nous travaillons principalement au niveau du **schéma RDF**, afin d'obtenir un résumé compact et interprétable.

Un **Basic Graph Pattern (BGP)** est un ensemble de triplets RDF pouvant contenir des variables. Chaque BGP correspond à un motif structurel exprimant un besoin informationnel utilisateur.

Nous définissons un **sous-graphe orienté requête** S_q comme le sous-graphe du schéma RDF induit par les classes et propriétés apparaissant dans un BGP donné q.

7.3 Construction des sous-graphes candidats

7.3.1 Extraction des fragments élémentaires

Pour chaque requête q appartenant à un ensemble de requêtes Q :

1. Extraction du BGP.
2. Identification des classes impliquées (via `rdf:type`, domaine et portée).
3. Identification des propriétés utilisées.
4. Construction du sous-graphe S_q correspondant.

On obtient ainsi un ensemble de fragments :

$$\mathcal{S} = \{S_{q_1}, S_{q_2}, \ldots, S_{q_n}\}$$

Chaque sous-graphe S_i représente un motif structurel réellement utilisé par les utilisateurs.

7.4 Estimation de l'importance des sous-graphes

Chaque sous-graphe S_i est considéré comme une unité atomique correspondant à un motif structurel issu des requêtes.

L'objectif est d'évaluer son importance en combinant des critères liés à l'usage et à la structure.

Fréquence d'usage La fréquence $\text{freq}(S)$ correspond au nombre d'occurrences du motif dans l'ensemble des requêtes Q.

Connectivité externe Afin d'évaluer l'importance structurelle du sous-graphe, nous définissons la connectivité externe comme le nombre de relations distinctes entre le sous-graphe et des nœuds externes :

$$\text{ExternalConnectivity}(S) = |\{(p, u) \mid u \notin V(S), \exists v \in V(S), (v, p, u) \in E\}|$$

Si plusieurs classes internes sont reliées au même nœud externe via la même propriété, une seule relation est comptabilisée.

Diversité des propriétés La diversité des propriétés est définie comme :

$$\text{Diversité}(S) = \frac{|\{p \mid (\cdot, p, \cdot) \in E(S)\}|}{|E(S)|}$$

Elle mesure la richesse relationnelle du motif.

Score global Après normalisation des différentes mesures, le score d'importance est défini comme :

$$I(S) = \alpha \cdot \text{freq}(S) + \beta \cdot \text{ExternalConnectivity}(S) + \gamma \cdot \text{Diversité}(S)$$

où α, β, γ sont des poids ajustables.
Cette combinaison permet de capturer :

— l'importance basée sur l'usage ;
— l'importance structurelle ;
— la richesse relationnelle.

7.5 Sélection des sous-graphes les plus importants

Les sous-graphes sont triés selon leur score d'importance. Les k sous-graphes les mieux classés sont sélectionnés pour former le cœur du résumé.

7.6 Connexion des sous-graphes sélectionnés

Les sous-graphes sélectionnés peuvent être disjoints. Afin d'obtenir un résumé connexe, ils sont reliés par :

— les classes communes existantes,
— ou les plus courts chemins dans le schéma RDF.

Cette étape peut être modélisée comme une approximation du problème du Steiner Tree, appliqué à des sous-graphes plutôt qu'à des nœuds individuels.

Le résumé final est l'union des sous-graphes sélectionnés augmentée des éléments nécessaires à leur connexion.

7.7 Évaluation

L'évaluation repose sur la métrique de *coverage* :

$$\text{Coverage} = \frac{\text{éléments couverts par le résumé}}{\text{éléments apparaissant dans les requêtes}}$$

Un bon résumé doit :

- couvrir un maximum de requêtes ;
- rester compact ;
- préserver la cohérence structurelle.